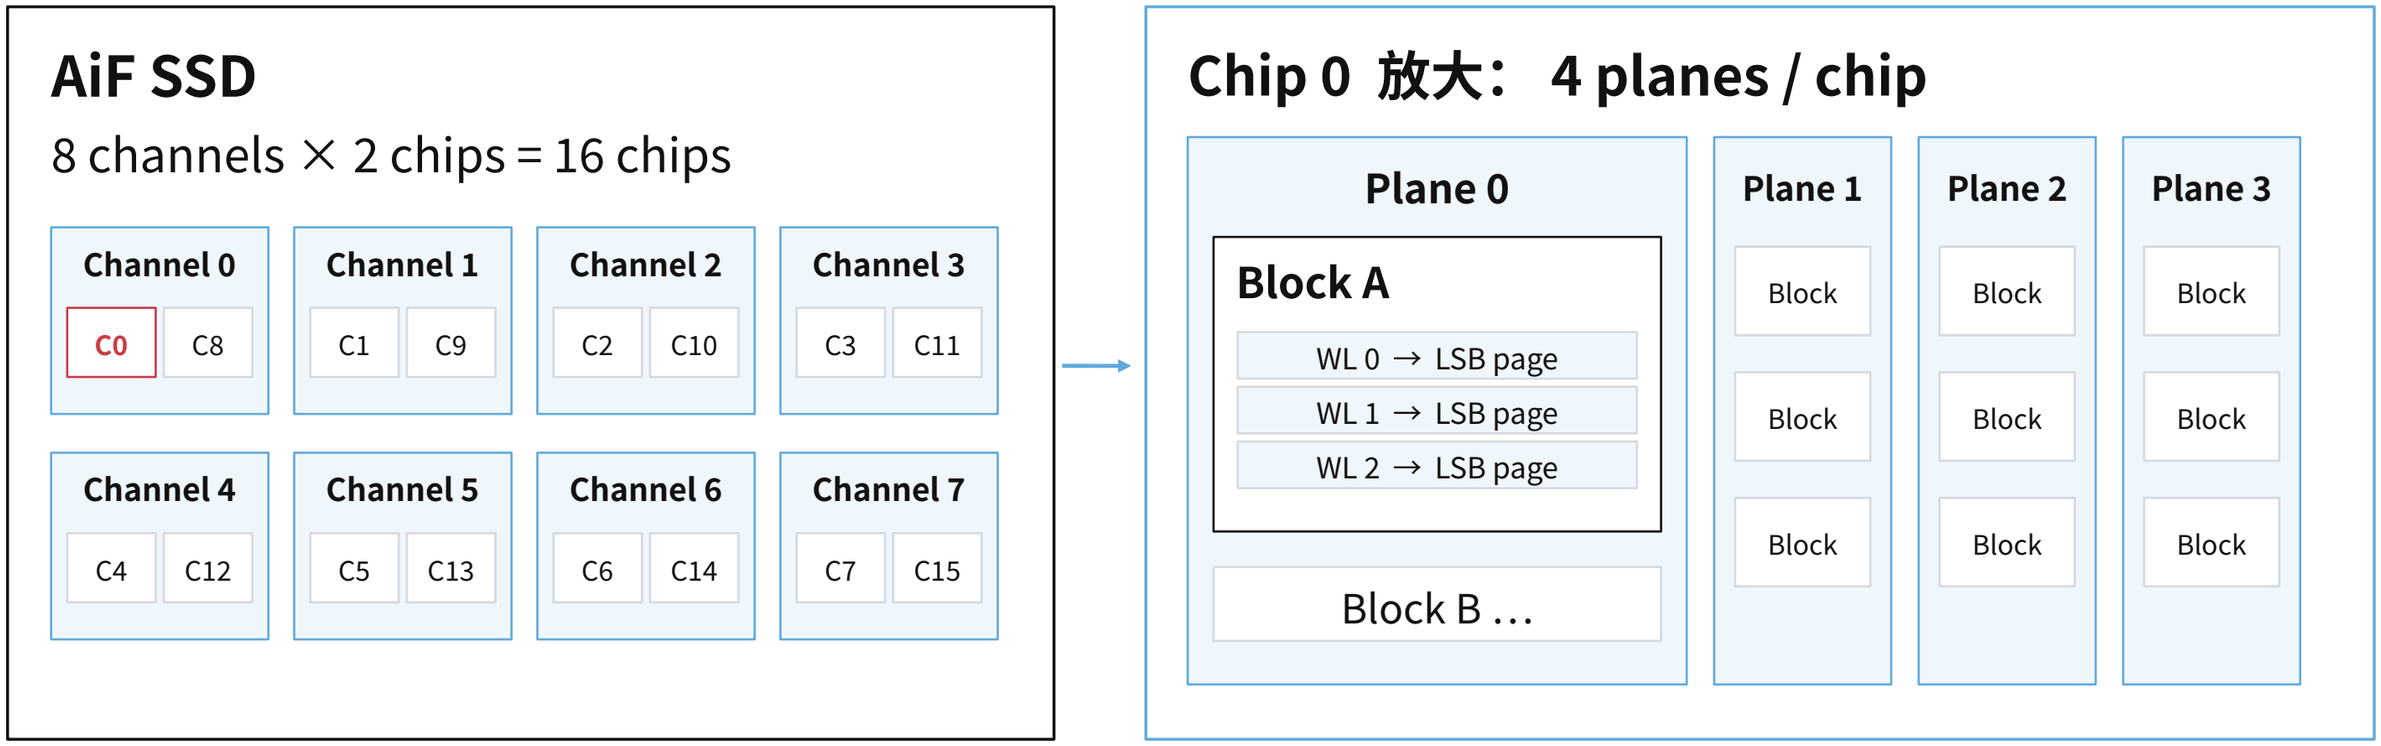


權重留在 chip 內讀取、修正錯誤與計算；主機主要交換向量。



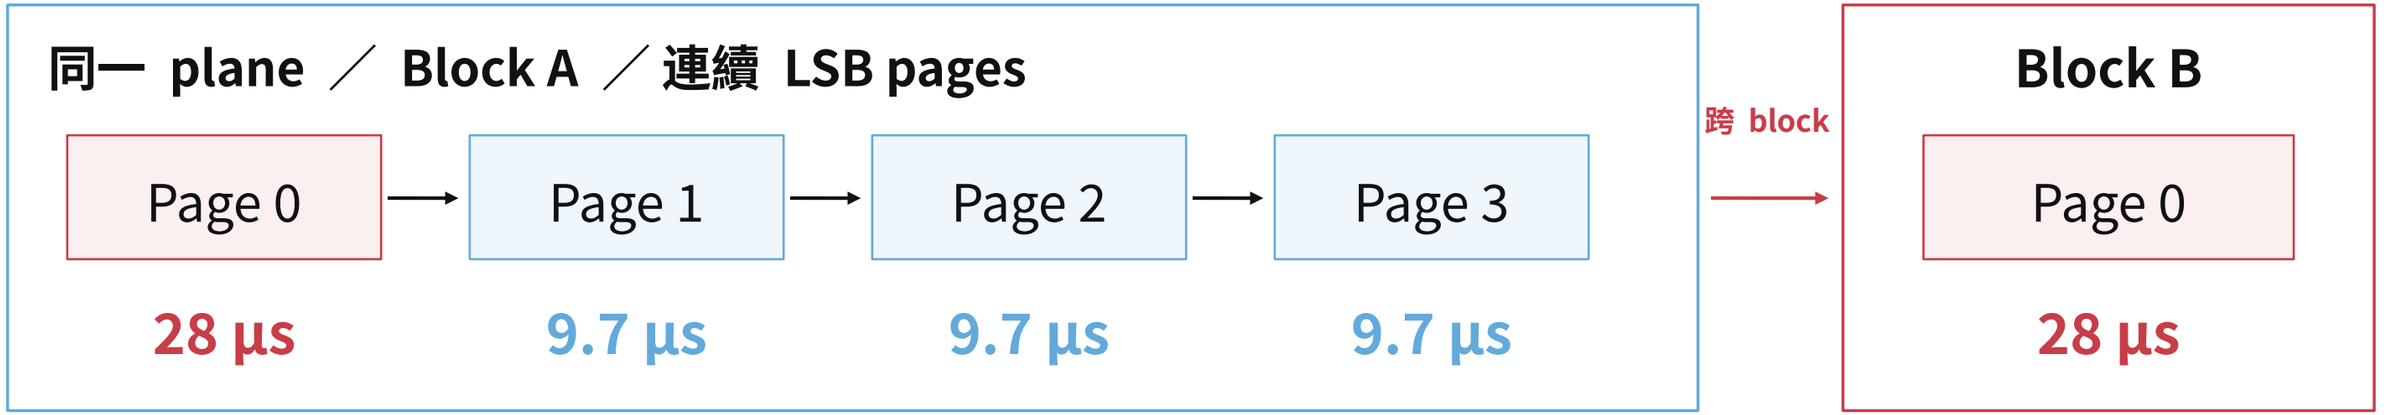
chip 內頻寬： 6.4 GB/s × 16 = 102.4 GB/s

LSB page： 16 KiB； 4-plane wave 最多讀 64 KiB

本專案採 192 WL/block （由論文量測資料推得）； die 未獨立建模。

cr-read：同一 block 內，不中斷地連續讀取

權重放在 LSB pages；第一頁付普通讀取成本，後續頁才能使用 cr-read。



跨 block 或開始新 stream，就要重新付一次 28 µs。

$$T_run(P) = 28 + (P - 1) \times 9.7\ \mu s$$

P：同一 plane ／ block 中連續讀取的頁數（P ≥ 1）

普通讀 4 頁
112 µs

連續讀 4 頁
57.1 µs

解析示例；28 µs 已包含整段的開始與結束成本。四 planes 可並行，chip 另受 6.4 GB/s 上限限制。

要看單個 expert 的 projection 大小，才能判斷切分是否太細

INT8： 1 projection = H × I bytes； 1 expert = 3 × H × I bytes

模型／總參數	H × I	Experts E / top-k	Routed 層數	單 projection	單 expert	全部 routed INT8 權重
Granite 3.1 A400M 1.335 B	1024 × 512	32 / 8	24	0.5 MiB	1.5 MiB	1.125 GiB
OLMoE 1B 7B 6.919 B	2048 × 1024	64 / 8	16	2 MiB	6 MiB	6 GiB
DeepSeek V2 Lite 15.706 B	2048 × 1408	64 / 6	26	2.75 MiB	8.25 MiB	13.406 GiB

Granite 的 0.5 MiB projection 切到 16 chips： 每 chip 只有 32 KiB 。

Routing 用 GGUF： Granite Q4 0.765 GiB ｜ OLMoE Q4 3.924 GiB ｜ DeepSeek Q8 15.555 GiB

總參數由 GGUF tensors 加總。 INT8 欄只含 routed experts； DeepSeek 排除首層 dense 與 shared experts 。

GGUF metadata； results/experiment_manifest.json； docs/aif_model_notes.md

分組可以讓單條 stream 變長，也讓不同 experts 並行

g = 每個 expert 使用的 chip 數；總共固定 16 chips，因此 groups = 16 / g。

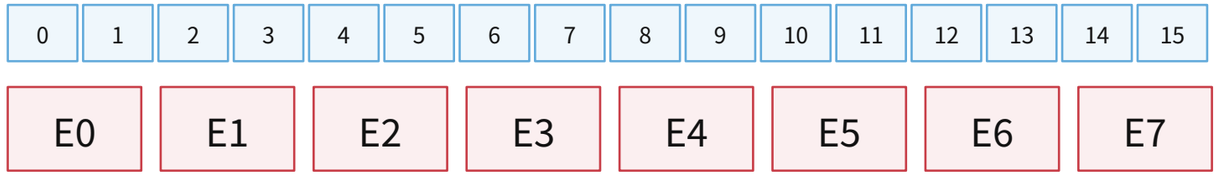
$T_{stream} = 28 + (w - 1) \times 9.7\ \mu s$

w = 向上取整［每 chip bytes / 64 KiB］

$T_{phase} \approx n_{max} \times T_{stream}$

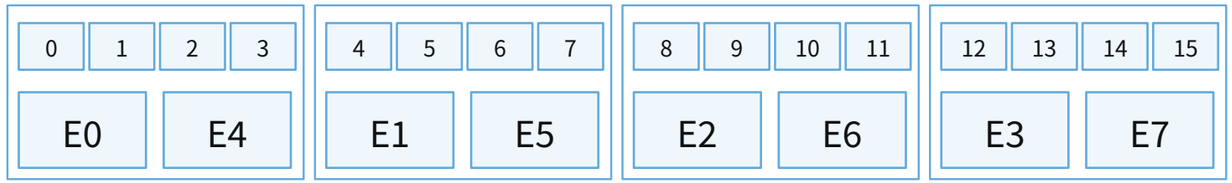
n_max：同時選中 experts 在最忙 group 的數量

同樣 8 個 experts： g = 16



1 個 group，8 個 experts 依序處理 → 224 µs

改為 g = 4： 4 個 groups 可同時工作



每組 2 個 experts → 2 × 37.7 = 75.4 µs

Granite： 512 KiB / projection	g = 16	g = 8	g = 4
每 chip 權重	32 KiB	64 KiB	128 KiB
四 -plane waves： w	1	1	2
單條 stream （µs）	28	28	37.7
groups	1	2	4
最忙 group： n_max	8	4	2
整個 phase （µs）	224	112	75.4

單 expert 較慢，整批仍可能更快。

示意假設： 8 experts 理想均衡、單一 projection phase；未串接 gate/up，不含控制／向量成本。真實 routing 可能碰撞。

gate/up 串接延長連續讀取；固定排列減少 group 排隊

Granite 、 g = 16 的簡單例子： gate/up 共用同一份輸入 x 。

分開存放 **28 + 28 = 56 µs**

gate： 32 KiB + up： 32 KiB

→

實體串接成連續 2I × H 矩陣

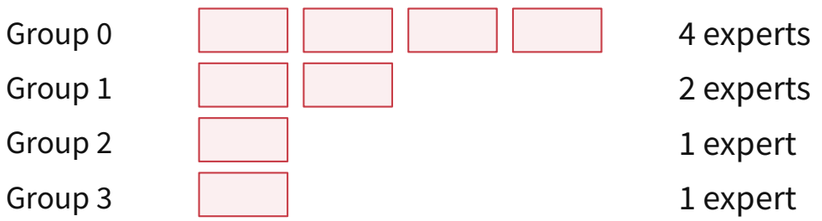
[gate ; up]： 64 KiB

一次 28 µs

x → [gate ; up] → 拆回輸出 → activation(gate) ⊙ up → down

固定排列：把常一起啟用的 experts 放到不同 groups

原排列



最忙 group： 4 個 experts 排隊

→

調整固定 slots 後



最忙 group： 2 個 experts 排隊

下半部為示意；選中的 experts 不變，僅交換固定位置，保留各組容量。權重與 router 都不重新訓練。

scripts/aif_model.py:stack_gate_up ； scripts/optimize_placement.py ； docs/placement_permutation_findings.md

固定真實 routing，比較配置，再以 NVMeVirt 重播核對

真實 llama.cpp
3 模型、 3 prompts
每組 32 次 decode

→

掃描配置
g = 1 / 2 / 4 / 8 / 16
串接與固定排列

→

保留 prompt 驗證
2 組訓練、 1 組保留
輪流做 3 折

→

NVMeVirt 重播
實際送入 NVMe queue
核對 kernel counters

三折：只用訓練 prompts 選配置

	說明	程式	數學
Fold 1	保留驗證	訓練	訓練
Fold 2	訓練	保留驗證	訓練
Fold 3	訓練	訓練	保留驗證

v3： controller 複製輸入向量

每份 logical input 只經 PCIe 傳一次

Chip command	0.25 µs
Host phase	2 µs
PCIe / channel	8 / 2 GB/s
輸入 / 輸出元素	1 / 4 bytes

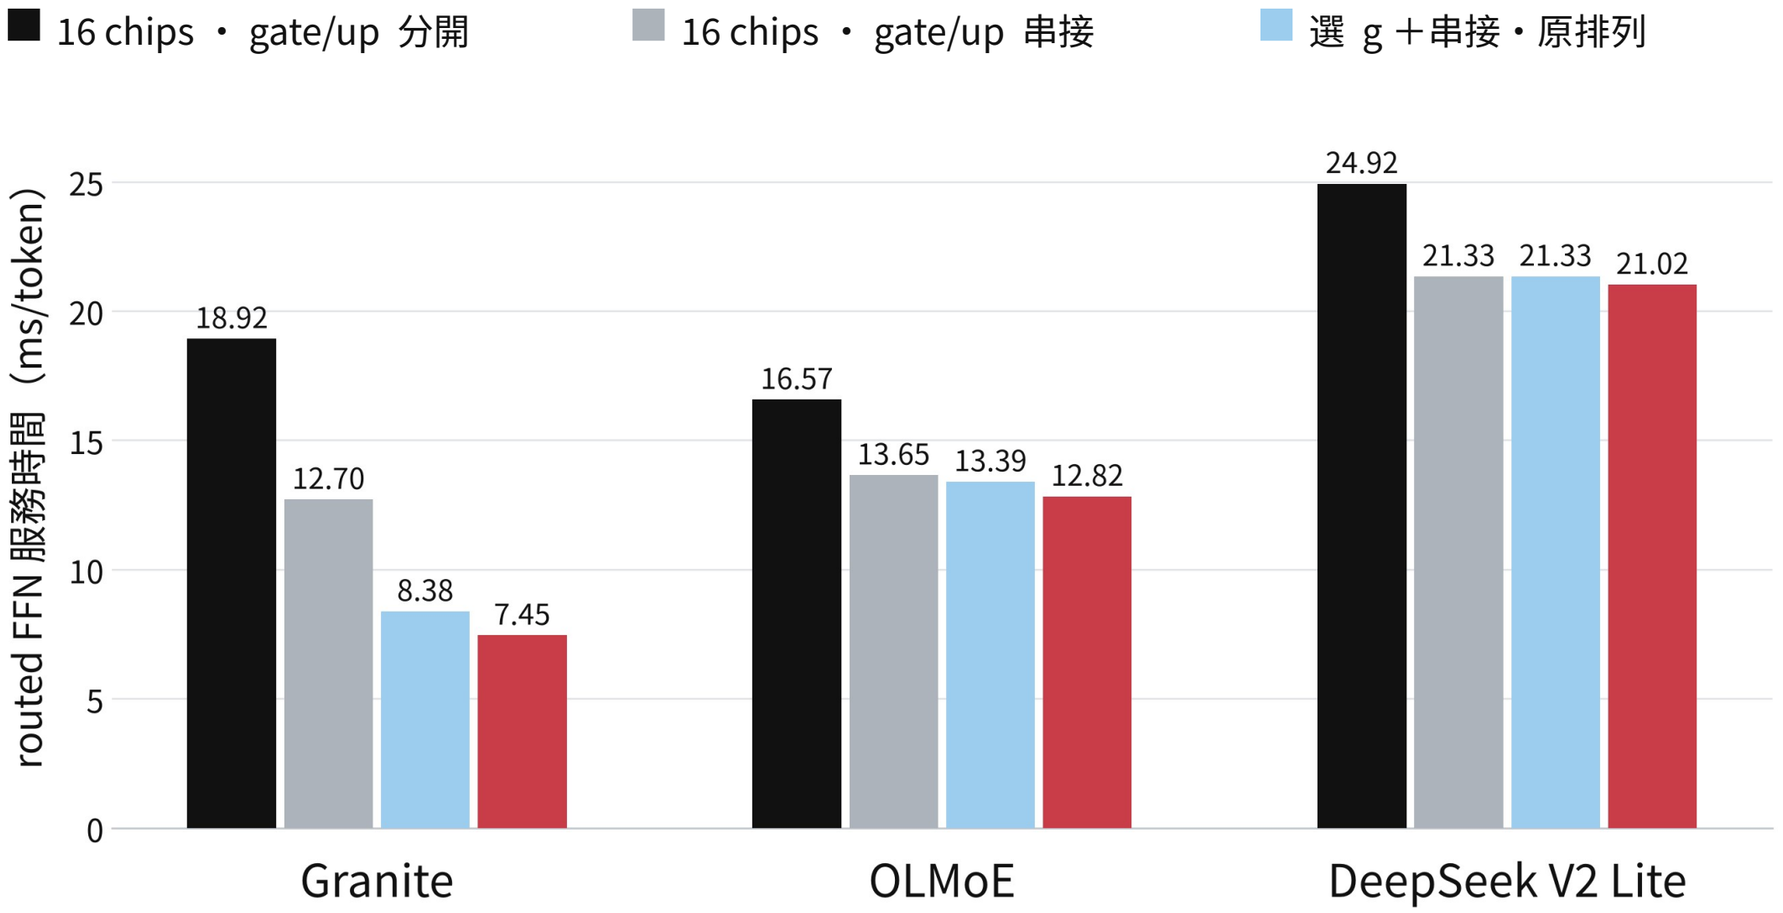
命令延遲與向量精度為展示假設，待硬體校準。

v3 驗證： 48 workloads ／ 183,744 NVMe commands ／ counters 全部相符

以下為建模的 routed FFN 服務時間；非實體 AiF 硬體或完整模型推論速度。

README.md； scripts/evaluate_learned_overhead.py； results/nvmevirt_validation.json； results/experiment_manifest.json

Granite 改善最明顯；相同方法對三個模型的收益不同



Granite · g = 4
−41.34%
12.703 → 7.452 ms

OLMoE · g = 8
−6.04%
13.648 → 12.824 ms

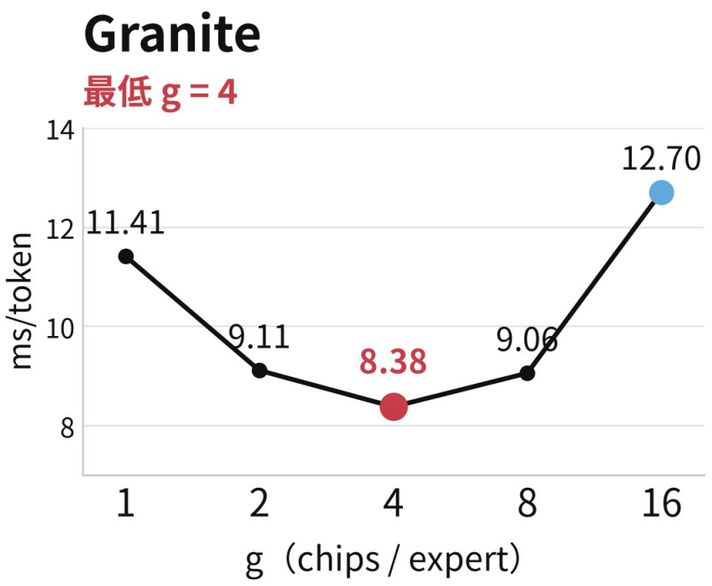
DeepSeek · g = 8
−1.49%
21.333 → 21.015 ms

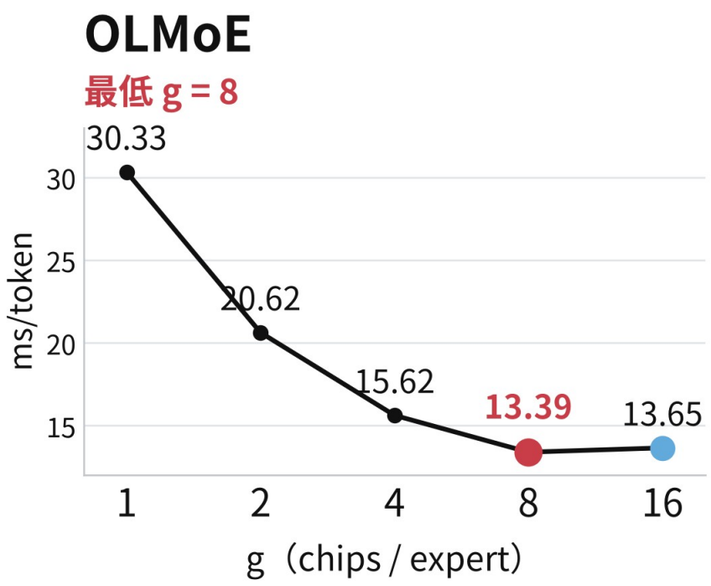
降低幅度皆相對
16-chip 已串接基準

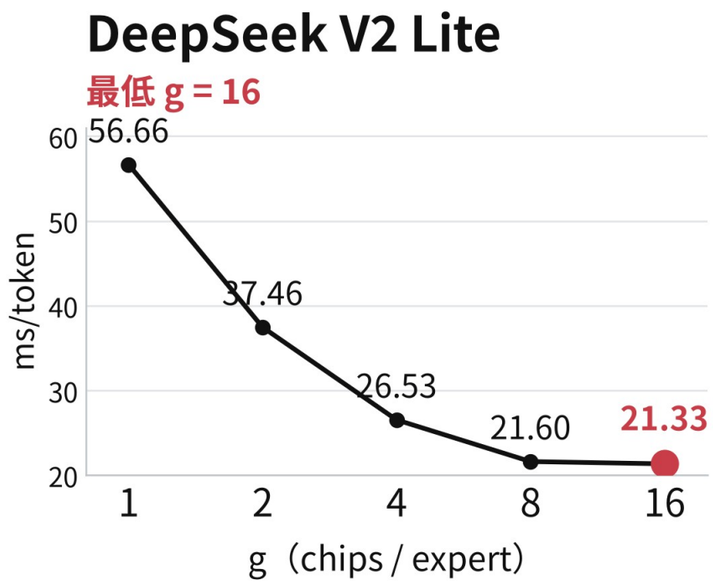
三折保留 prompt 平均。 DeepSeek 原排列選 g=16，學習排列選 g=8。

g 沒有通用答案： expert 尺寸、碰撞與控制成本要一起看

固定原排列、 gate/up 已串接；三組 prompts 合併平均（各圖 y 軸依模型縮放）。







DeepSeek： 原排列 g=16 → 學習排列 g=8 ，總時間仍可從 21.333 降至 21.015 ms 。

Flash +0.417 ms **控制 − 0.624 ms** **輸入 − 0.110 ms** **合計 − 0.318 ms**

配置選擇需同時看 flash 、命令與傳輸；本輪只有三個短 prompts ，控制成本仍待硬體校準。